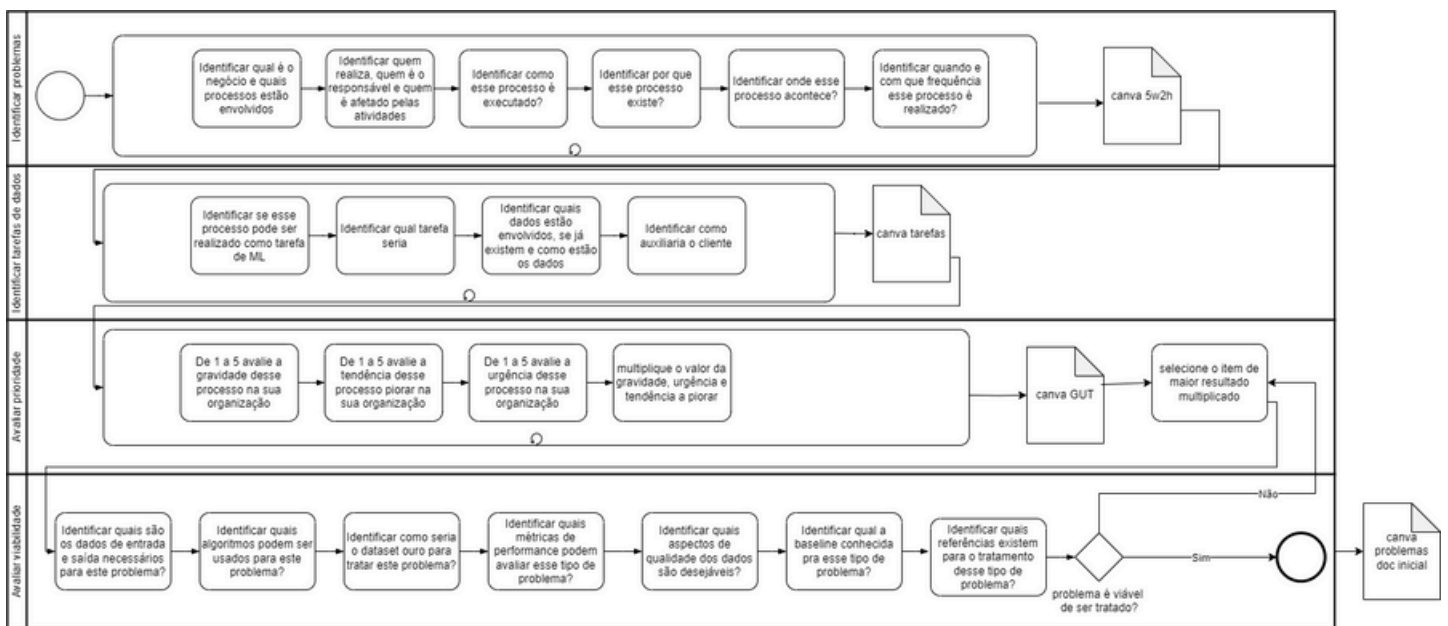


Identification Problems for AI Projects Innovations

Ao participar da Pós Graduação UFG e obter instruções da professora Mariana Martins recebemos a tarefa de identificar a maior dificuldade do projeto apresentado e identificação do problema. Etapa inicial no desenvolvimento de soluções ML e que tem intersecção com a engenharia de requisitos.

A ideia é aplicar o processo identificando inicialmente o negócio e os processos existentes envolvidos no negócio. Também buscamos identificar (caso exista um possível problema a ser tratado com solução ML). Então aplicamos a matriz GUT que avalia a gravidade, urgência e tendência a piorar de cada um dos processos ou problemas apresentados. Multiplicamos o valor a fim de identificar qual processo é mais prioritário a ser tratado no projeto. A seguir Aplicamos o 5W2H para identificar tarefas existentes no processo, envolvidos, como: responsável, quem realiza a atividade e quem é afetado por ela. Também identificamos onde a atividade acontece, como ela é realizada e registrada (ou seja, como os dados são gerados e armazenados), por quê determinada atividade acontece e sua importância e com que frequência essa atividade é realizada. A seguir contamos com o cientista de dados para identificar a tarefa de dados associada aos problemas identificados, quais dados são necessários para tratar cada problema e como poderíamos obtê-los e também listamos como essa solução ajuda o cliente. Por fim, aplicamos a identificação do problema a ser tratado no projeto, quais são os dados de entrada e saída, quais são as características de qualidade dos dados necessários e qual seria o dataset ouro. como seriam as métricas de performance, qual baseline existente para esse tipo de problema e as referências.


A abordagem de processo foi criada durante o doutorado de Mariana Martins no Instituto de Informática da Universidade de Goiás, supervisionada pelo Prof. Renato Bulcão-Neto com o apoio da Profa. Taciana Novo Kudo. A técnica foi aplicada primeiramente em projetos de aprendizado de máquina do CEIA - UFG e evoluiu ao longo de uma série de estudos científicos. Hoje ela está sendo usada por diversas empresas e inclusive em nosso trabalho de Pós Graduação sobre a supervisão da mesma. Abaixo está uma lista de alguns dos estudos científicos, que inclusive relatam resultados da aplicação da técnica em empresas.



MARTINS, M.; KUDO, T.; BULÇÃO-NETO, R. A qualitative study on requirements engineering practices in an artificial intelligence unit of the brazilian industrial research and innovation company. In: Anais do XXVII Congresso Ibero-Americano em Engenharia de Software, p. 46-60, Porto Alegre, RS, Brasil, 2024. SBC.

MARTINS, M.; KUDO, T.; BULÇÃO-NETO, R. A requirements engineering process for machine learning innovation projects. In: Anais do XXVII Workshop de Engenharia de Requisitos, Buenos Aires, Argentina, 2024. Even3.

MARTINS, M.; MANCINE, L.; RODRIGUES, J.L.; KUDO, T.; BULÇÃO-NETO, R. Research Synthesis in Requirements Engineering for Machine Learning-Based AI Systems: A Tertiary Study. (SUBMETIDO).



Marcos Vinicius Satil Medeiros é um cientista de dados aluno do curso de Pós graduação da UFG.



Wagner Hélio da Silva é um engenheiro de dados aluno do curso de Pós graduação da UFG.



Pedro Koziel Diniz é um cientista de dados aluno do curso de Pós graduação da UFG.

Identificação de Objetivos do Negócio

Propósito: Identificar o contexto da organização, processos, problemas e oportunidades que podem ser resolvidas com soluções de inteligência artificial (IA) em projetos de pesquisa, desenvolvimento e inovação (PDI)

Os stakeholders envolvidos no preenchimento deste artefato e identificação de problemas para projetos de PDI são: Business Owner (BO), Especialista de Domínio (ED) e Cientista de Dados (CD)

Objetivo do negócio 1	Justificativas 2	Benefícios 3
<ul style="list-style-type: none">• Responder LAIs de maneira sistêmica utilizando Inteligência Artificial e LLMs para busca em base dados e entrega de resultados para o cliente. BO	<ul style="list-style-type: none">• A Secretaria de Segurança Pública lida com grandes volumes de dados provenientes de investigações, laudos periciais e registros criminais.• A análise manual desses dados é lenta e sujeita a erros, prejudicando a velocidade e a precisão dos resultados. BO	<ul style="list-style-type: none">• Redução de erros humanos.• Eficiência: Necessidade de busca manual apenas em casos mais específicos.• Facilitação de cruzamento de dados entre inquéritos e ocorrências.• Transparência: Histórico de consultas e resultados acessíveis para auditoria e controle. BO
KPIs 4	Processos para atingir o objetivo 5	
<ul style="list-style-type: none">• Segurança e auditoria das ocorrências e inquéritos.• Tempo médio de resposta às consultas (reduzir em X%)• Taxa de erro nas buscas de informações (reduzir em X%)• Redução de retrabalho em consultas repetidas (reduzir em X%) BO	<ul style="list-style-type: none">• Definir diagrama de processos.• Configuração e customização do ambiente.• Correlacionamento de informações entre múltiplas bases de dados.• Interface simplificada ou api para os atendentes acessarem o agente de IA. BO	
Problemas necessários de serem tratados 6		
<ul style="list-style-type: none">• Lentidão na busca manual de dados, por conta de autorização de burocráticas de órgãos detetores da informação.• Falta de integração entre diferentes bases de dados (banco de dados relacionais e NoSQL e bancos transacionais relacionais).• Erros humanos ao localizar ou interpretar informações críticas.• Sobrecarga de trabalho nos atendentes, que perdem tempo em buscas manuais repetidas.• Falta de padronização na criação de relatórios e laudos. BO		

Resultados esperados: Lista de possíveis problemas a serem tratados com solução de AM em projetos PDI

Análise de Viabilidade

Propósito: Avaliar se o tratamento do(s) problema(s) é viável de ser tratado com solução de IA neste projeto analisando aspectos de dados, soluções e riscos

<div><div>Problema prioritário</div><div>17</div><div><ul style="list-style-type: none">• Converter bases de dados relacionais e não relacionais em informação útil para os LLMs.• Busca de informações relevantes nas bases de dados;</div><div><div>BO</div><div>CD</div></div></div>	<div><div>Dados entrada</div><div>18</div><div><ul style="list-style-type: none">• Query do usuário, LAIs.• Estrutura dos banco de dados, Ocorrências (Banco SQL e NoSQL)</div><div><div></div><div></div><div></div><div></div></div></div>	<div><div>Qualidade dos dados</div><div>19</div><div><ul style="list-style-type: none">• Completude: o banco de dados deve conter todas as informações relevantes.• Consistência: Padronização nos formatos dos campos.• Atualização: Dados devem ser atualizados periodicamente.</div><div><div></div><div>BO</div><div>CD</div></div></div>
<div><div>Dados saída</div><div>20</div><div><ul style="list-style-type: none">• Resposta à query feita, em linguagem natural.• Logs de acesso• Dashboard interativo.</div><div><div></div><div>CD</div></div></div>	<div><div></div><div></div><div></div><div></div></div> <div><div></div><div>BO</div><div>ED</div><div>CD</div></div>	<div><div>Métricas de desempenho</div><div>21</div><div><ul style="list-style-type: none">• Taxa de precisão das respostas.• Redução no tempo de geração das LAIs• Quantidade de consultas repetidas reduzidas;</div><div><div></div><div>CD</div></div></div>
<div><div>Riscos</div><div><ul style="list-style-type: none">• Dados incompletos ou inconsistentes; Resistência dos usuários ao novo sistema; Falha de integração com sistemas legados;</div><div>22</div></div> <div><div>Descrição - Impacto - Probabilidade - Contingência</div><div><ul style="list-style-type: none">• identifique riscos - julgue o impacto de cada risco (ex. atrasos no projeto) - informe a probabilidade dos risco acontecer como baixa, média e alta - descreva as ações a serem tomadas caso o risco aconteça</div><div><div></div><div>BO</div><div>CD</div></div></div>		
<div><div>Algoritmos</div><div>23</div><div><ul style="list-style-type: none">• Modelos de linguagem para a tarefa de Text2SQL;• Modelos open source.• Modelos de embeddings e semelhança - RAG.</div><div><div></div><div>CD</div></div></div>	<div><div>Baseline</div><div>24</div><div><ul style="list-style-type: none">• Spider benchmark (https://www.databricks.com/blog/improving-text2sql-performance-ease-databricks?utm_source=chatgpt.com)• BIRD-SQL (https://bird-bench.github.io/?utm_source=chatgpt.com)• WikiSQL (https://paperswithcode.com/dataset/wikisql)</div><div><div></div><div>CD</div></div></div>	<div><div>Referências</div><div>25</div><div><ul style="list-style-type: none">• https://arxiv.org/html/2406.08426v1• https://arxiv.org/abs/2308.15363• https://arxiv.org/abs/2403.02951• https://arxiv.org/abs/2407.15186</div><div><div></div><div>CD</div></div></div>

Resultados esperados: Problemas viáveis de serem tratados com soluções AM em projetos de PDI